



Panduan Scraping & Seeding Data VIYGO

Dokumen ini menjelaskan **apa saja yang sudah dilakukan, bagaimana sistem ini bekerja, dan cara menggunakannya kembali** untuk menambah data baru.

Daftar Isi

1. Ringkasan Apa yang Sudah Dilakukan
2. Struktur File
3. Penjelasan Tiap File
4. Cara Menggunakan Data yang Sudah Ada
5. Cara Scrape Data Baru
6. Cara Memasukkan Data Baru ke Database
7. Koreksi Scraping Chrome Extension
8. Login Akun Testing
9. Troubleshooting

1. Ringkasan Apa yang Sudah Dilakukan

Masalah Awal

Kalian scrape data dari Treatwell.co.uk menggunakan Chrome Extension (Web Scraper), hasilnya file Excel dengan **105 kolom yang tidak terstruktur** — kolom bernama `data`, `data2`, `data3`... sampai `data35`, data tercampur dalam satu sel, dan banyak kolom yang isinya salah.

Yang Sudah Dikerjakan

No	Yang Dikerjakan	Hasil
1	Analisis Excel — Memetakan 105 kolom ke field yang benar	Identifikasi 15+ kolom penting dari 105 kolom
2	Python Parser (Excel) — Script untuk membersihkan data Excel	<code>parse_treatwell_excel.py</code>
3	JavaScript Scraper — Script scraping yang lebih baik	<code>treatwell_scraper.js</code>
4	Python Parser (JSON) — Parser untuk hasil scraping baru	<code>parse_treatwell_json.py</code>
5	6 File JSON — Data bersih siap masuk database	<code>database/data/*.json</code>
6	8 Laravel Seeders — File seeder untuk semua tabel	<code>database/seeders/*.php</code>
7	Testing — Semua data berhasil masuk database	✅ 3,200+ records

Data yang Sudah Masuk Database

Tabel	Jumlah Record	Keterangan
kota	87	Kota-kota di UK (area Birmingham & sekitar)
kategori	10	Hair, Face, Nails, Massage, Body, dll
users	182	1 admin + 1 customer + 180 salon owners
salon	180	Salon dari Treatwell (nama, alamat, rating, dll)
service	1.962	Layanan tiap salon (nama, harga, durasi)
staff	254	Staff/karyawan tiap salon
salon_images	529	Foto-foto salon (URL CDN Treatwell)
TOTAL	3.204	

2. Struktur File

```

database/
├── data/
│   ├── kota.json           ← Data bersih (JSON)
│   │                       (87 records)
│   ├── kategori.json      (10 records)
│   ├── salon.json         (180 records)
│   ├── service.json       (1.962 records)
│   ├── staff.json         (254 records)
│   └── salon_images.json  (529 records)
├── scripts/
│   ├── treatwell_scraper.js ← Tools scraping & parsing
│   ├── parse_treatwell_excel.py ← Script scraping (Chrome Console)
│   └── parse_treatwell_json.py ← Parser Excel → JSON
│                                   ← Parser JSON scraper → JSON database
├── seeders/
│   ├── DatabaseSeeder.php ← Laravel Seeders
│   ├── KotaSeeder.php     ← Master (menjalankan semua)
│   ├── KategoriSeeder.php
│   ├── UserSeeder.php
│   ├── SalonSeeder.php
│   ├── ServiceSeeder.php
│   ├── StaffSeeder.php
│   └── SalonImagesSeeder.php
└── treatwell-co-uk-2026-04-14.xlsx ← Data Excel asli (sudah di-parse)

```

3. Penjelasan Tiap File

● Scripts (Tools)

database/scripts/treatwell_scraper.js

Apa ini? Script JavaScript untuk scraping data dari website Treatwell.co.uk.

Bagaimana cara kerjanya?

1. Kamu paste script ini di Chrome Console (F12 → Console)
2. Script membaca semua salon di halaman listing
3. Untuk tiap salon, script membuka halaman detailnya
4. Di halaman detail, script mengambil **JSON-LD** (structured data yang sudah rapi)
5. Hasilnya di-download otomatis sebagai file **.json**

Kenapa lebih baik dari Chrome Extension?

- Data sudah **terstruktur** karena ambil dari JSON-LD (data SEO yang pasti ada)
 - Tidak ada kolom campur aduk seperti **data**, **data2**, **data3**
 - Otomatis navigate ke halaman detail tiap salon
-

database/scripts/parse_treatwell_excel.py

Apa ini? Parser Python yang membersihkan data dari Excel hasil Chrome Extension.

Kapan dipakai? Hanya jika kalian scrape pakai Chrome Extension dan hasilnya Excel.

Apa yang dilakukan?

- Membaca 105 kolom Excel dan memetakan ke field yang benar
- Mem-parse data tercampur (contoh: kolom **Discount_Information** berisi nama service + harga + durasi dalam 1 sel)
- Mengekstrak nama staff dari teks yang disambung tanpa spasi
- Output: 6 file JSON di **database/data/**

Cara pakai:

```
# Pastikan openpyxl sudah terinstall
pip install openpyxl

# Letakkan file Excel di database/
# Jalankan:
python database/scripts/parse_treatwell_excel.py
```

database/scripts/parse_treatwell_json.py

Apa ini? Parser Python untuk mengkonversi hasil **treatwell_scraper.js** ke format database.

Kapan dipakai? Setelah scraping baru menggunakan **treatwell_scraper.js**.

Cara pakai:

```
# Letakkan file JSON hasil scraping di database/data/  
python database/scripts/parse_treatwell_json.py  
database/data/treatwell_scrape_2026-04-17.json
```

● Seeders (Laravel)

database/seeders/DatabaseSeeder.php

Master seeder — menjalankan semua seeder dalam urutan yang benar sesuai foreign key:

1. KotaSeeder ← Tidak ada FK
2. KategoriSeeder ← Tidak ada FK
3. UserSeeder ← Tidak ada FK
4. SalonSeeder ← FK ke users + kota
5. ServiceSeeder ← FK ke salon + kategori
6. StaffSeeder ← FK ke salon
7. SalonImagesSeeder ← FK ke salon

⚠ **PENTING:** Urutan ini TIDAK BOLEH diubah! Kalau diubah, akan error karena foreign key constraint.

Seeder Lainnya

Setiap seeder:

1. Membaca file JSON dari database/data/
2. Menggunakan **chunked insert** (100 records per batch) untuk efisiensi
3. Menampilkan jumlah record yang berhasil di-seed

● Data Files (JSON)

Semua file JSON di database/data/ sudah siap pakai. Formatnya:

kota.json:

```
{  
  "id_kota": 1,  
  "nama_kota": "Birmingham",  
  "provinsi": "West Midlands"  
}
```

salon.json:

```
{
  "id_salon": 1,
  "id_user": 1,
  "id_kota": 48,
  "nama_salon": "Bamboo Hair & Aesthetic",
  "alamat": "191 Church Road, Yardley, Birmingham, B25 8UR",
  "deskripsi": "Welcome to Bamboo Hair & Aesthetic...",
  "opening_time": "10:00",
  "closing_time": "17:30",
  "rating": 4.4,
  "total_review": 103,
  "status": "active"
}
```

service.json:

```
{
  "id_service": 1,
  "id_salon": 1,
  "id_kategori": 5,
  "nama": "Children - Wash, Haircut & Blow Dry",
  "durasi": 45,
  "harga": 25.0,
  "status": "active"
}
```

4. Cara Menggunakan Data yang Sudah Ada

Seed Database (Data Sudah Ada)

Data sudah di-parse dan tersimpan di `database/data/*.json`. Tinggal jalankan:

```
cd d:\VIYGO\viygo-app

# Opsi 1: Reset database + isi data (MENGHAPUS SEMUA DATA LAMA!)
php artisan migrate:fresh --seed

# Opsi 2: Seed saja tanpa reset migration
php artisan db:seed

# Opsi 3: Seed tabel tertentu saja
php artisan db:seed --class=SalonSeeder
php artisan db:seed --class=ServiceSeeder
```

⚠ `migrate:fresh` akan **MENGHAPUS SEMUA TABEL** dan membuatnya ulang. Gunakan hanya saat development!

Waktu Eksekusi

- Migration: ~2 detik
- Seeding: ~35 detik (sebagian besar untuk hashing 180 password user)
- **Total: ~37 detik**

5. Cara Scrape Data Baru

Step-by-Step

Langkah 1: Buka Halaman Listing Treatwell

Buka Chrome, navigasi ke URL listing. Contoh URL per kota:

```
# HAIR
https://www.treatwell.co.uk/places/treatment-group-hair/in-london/
https://www.treatwell.co.uk/places/treatment-group-hair/in-manchester/
https://www.treatwell.co.uk/places/treatment-group-hair/in-leeds/
https://www.treatwell.co.uk/places/treatment-group-hair/in-edinburgh/

# NAILS
https://www.treatwell.co.uk/places/treatment-group-nails/in-london/
https://www.treatwell.co.uk/places/treatment-group-nails/in-manchester/

# MASSAGE
https://www.treatwell.co.uk/places/treatment-group-massage/in-london/

# FACE / BEAUTY
https://www.treatwell.co.uk/places/treatment-group-face/in-london/
```

Langkah 2: Buka Console

Tekan **F12** → klik tab **Console**

Langkah 3: Paste Script

1. Buka file `database/scripts/treatwell_scraper.js`
2. Copy **SEMUA** isi file
3. Paste di Console
4. Tekan **Enter**

Langkah 4: Tunggu

- Script akan berjalan otomatis
- Kamu bisa lihat progress di Console:

```
🚀 Starting Treatwell Scraper...
📄 Page 1: https://www.treatwell.co.uk/places/...
Found 20 salons
[1/20] Scraping: Bamboo Hair & Aesthetic
[2/20] Scraping: Polish & Glow Shirley
...
✅ Page 1 done. Total salons collected: 20
```

- **Jangan tutup tab!** Biarkan sampai selesai.

Langkah 5: Download Otomatis

Setelah selesai, file JSON akan otomatis ter-download dengan nama seperti:

```
treatwell_scrape_2026-04-17.json
```

Langkah 6: Konfigurasi (Opsional)

Di bagian atas script, kamu bisa ubah setting:

```
const MAX_PAGES = 50;           // Jumlah halaman maksimum (1 halaman ≈ 20 salon)
const DELAY_MS = 2000;          // Delay antar halaman (ms)
const DETAIL_DELAY_MS = 3000;   // Delay antar detail page (ms)
```

💡 **Tips:** Untuk coba-coba, set `MAX_PAGES = 2` dulu (≈ 40 salon). Kalau sudah berhasil, naikan ke 50.

Tips Anti-Block

❌ Jangan

✅ Lakukan

Scrape 500 salon sekaligus	Scrape 50-100 per sesi, jeda 30 menit
Delay 0-1 detik	Delay minimal 3 detik
Scrape dari 1 IP terus menerus	Ganti VPN/koneksi jika di-rate-limit
Scrape halaman yang sama berulang	Simpan hasil, jangan scrape ulang


6. Cara Memasukkan Data Baru ke Database

Alur Lengkap: Scrape → Parse → Seed

1. SCRAPE

2. PARSE

3. SEED



Command Lengkap

```
# 1. Pindahkan file hasil scraping ke folder data
move C:\Users\[username]\Downloads\treatwell_scrape_2026-04-17.json
d:\VIYGO\viygo-app\database\data\

# 2. Parse ke format database
cd d:\VIYGO\viygo-app
python database/scripts/parse_treatwell_json.py
database/data/treatwell_scrape_2026-04-17.json

# 3. Cek hasil (opsional)
# Buka database/data/ dan periksa file JSON yang dihasilkan

# 4. Masukkan ke database
php artisan migrate:fresh --seed
```

Kalau Mau Gabungkan Data Lama + Baru

Jika kalian sudah punya data di `database/data/` dan mau **menambahkan** data baru tanpa kehilangan yang lama, kalian bisa gabungkan manual:

```
# Gabungkan JSON (pakai Python)
python -c "
import json
old = json.load(open('database/data/salon.json'))
new = json.load(open('database/data/treatwell_scrape_new.json'))
# ... gabungkan dan simpan
"
```

 **Rekomendasi saat development:** Lebih mudah `migrate:fresh --seed` setiap kali. Gabungkan data nanti saat sudah siap production.

7. Koreksi Scraping Chrome Extension

Masalah Utama

File Excel kalian ([treatwell-co-uk-2026-04-14.xlsx](#)) punya masalah ini:

1. Kolom Tidak Bernama Jelas

```
Kolom Excel: data, data2, data3, data4, ... data35
Seharusnya:  alamat, rating, opening_time, price, ... deskripsi
```

2. Data Tercampur dalam Satu Sel

Contoh isi kolom `Discount_Information`:

```
Ladies - Haircuts & Blow Drys(5)from £30Ladies - Hair Treatments & Styling(7)from
£40Ladies - Hair Colouring(7)from £15...Children - Wash, Haircut & Blow Dry 45
minsShow Details£25Select
```

Ini **satu sel** yang berisi nama layanan, jumlah varian, harga, durasi — semuanya disambung tanpa separator!

3. Kolom Salah Isi

```
Kolom: streetAddress (seharusnya alamat jalan)
Isi:   "Credit card accepted" ← INI BUKAN ALAMAT!
```

4. Solusi yang Sudah Diterapkan

Script `parse_treatwell_excel.py` menangani semua masalah ini:

- **Regex parsing** untuk memisahkan services dari blob `Discount_Information`
- **Heuristic mapping** untuk 105 kolom ke field yang benar
- **Fallback logic** kalau data di satu kolom salah, cari di kolom lain
- **Category guesser** berdasarkan keyword di nama service

8. Login Akun Testing

Setelah menjalankan `php artisan migrate:fresh --seed`:

Role	Email	Password
Admin	admin@viygo.com	password
Customer	customer@viygo.com	password
Salon Owner	owner_1@viygo.com	password
Salon Owner	owner_2@viygo.com	password

Role	Email	Password
...	...	...
Salon Owner	owner_180@viygo.com	password

Owner ke-N = pemilik salon ke-N. Contoh: `owner_1@viygo.com` adalah pemilik salon "Bamboo Hair & Aesthetic".

9. Troubleshooting

✗ Error: "Module not found: openpyxl"

```
pip install openpyxl
```

✗ Error: "Column count doesn't match"

Ini terjadi kalau struktur JSON tidak cocok dengan tabel. Pastikan:

1. Jalankan parser dulu sebelum seed
2. Gunakan `migrate:fresh --seed` (bukan `db:seed` saja)

✗ Error: "Foreign key constraint fails"

Urutan seeding salah. Pastikan `DatabaseSeeder.php` tidak diubah urutannya.

✗ Scraper di Console tidak jalan

- Pastikan kamu di halaman **listing** Treatwell (bukan homepage)
- Coba ketik `allow pasting` di Console kalau ada peringatan
- Pastikan URL mengandung `/places/`

✗ Seeding sangat lama (>1 menit)

Normal! `UserSeeder` hashing 180 password dengan bcrypt 12 rounds. Ini memang berat. Kalau mau lebih cepat saat development, ubah di `.env`:

```
BCRYPT_ROUNDS=4
```

✗ Mau reset dan seed ulang

```
php artisan migrate:fresh --seed
```

Ini akan menghapus semua tabel, membuat ulang, dan mengisi data dari JSON.

Catatan Akhir

- **Data saat ini** baru dari **area Birmingham** (180 salon). Kalian bisa scrape kota lain (London, Manchester, Leeds, dll) untuk menambah data.
- **Target realistis**: 1.000-1.500 salon dari 10+ kota UK
- **Scrape bertahap**: 50-100 salon per sesi, 2-3 sesi per hari
- Semua file yang dibuat sudah **ter-commit-ready** — tinggal `git add` dan `git commit`